

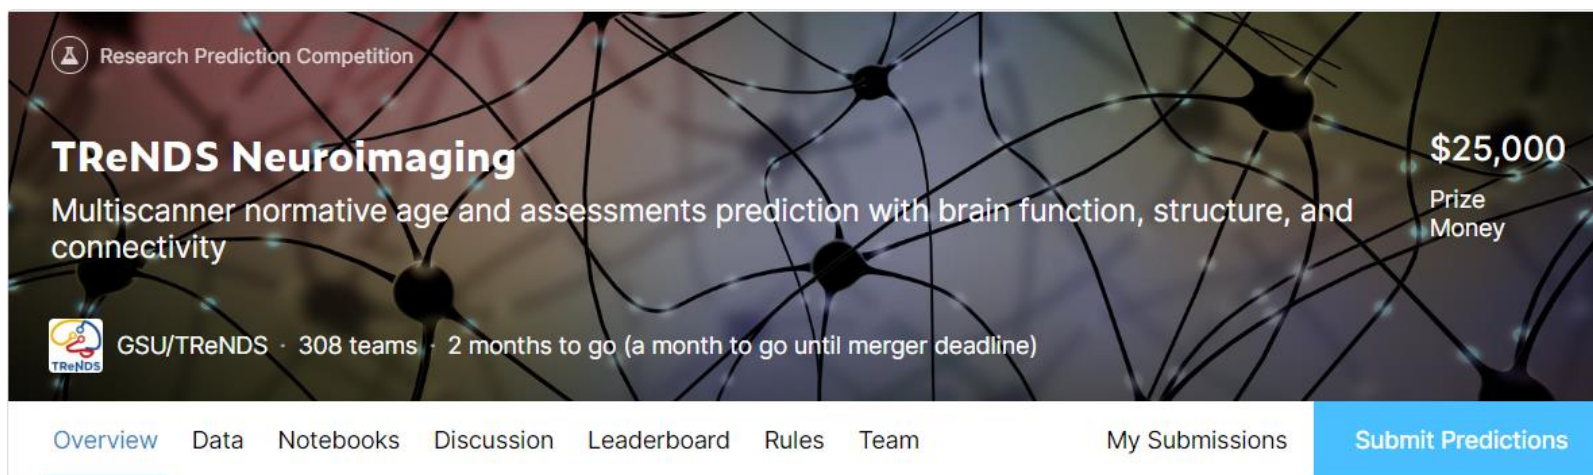
# Sprint 論文紹介

MEF2004

齋藤 拓実

# 論文選定の動機

- ・ 取り組んでいた Kaggle に活用できそうなものを選定



... 脳MRIのimage dataと、独立主成分分析で取り出されたtable dataから  
年齢等の変数を予測する回帰問題

→ 独立主成分分析について1本  
table data からのアプローチ (SVM, GPR) について2本  
image data からのアプローチ (CNN) について2本

選定

# Decoding the Encoding of Functional Brain Networks: an fMRI Classification Comparison of Non-negative Matrix Factorization (NMF), Independent Component Analysis (ICA), and Sparse Coding Algorithms

(2017) Jianwen Xie et al

<https://arxiv.org/abs/1607.00435>

## どんなもの？

Functional MRI (fMRI) での機能ネットワークは、独立主成分分析を使用して識別されることが多いが、このほかに信号が陽性であることを仮定した非負値行列因子分解 (NMF) や、スパース性をもたせるL1正則化学習、特異値分解 (K-SVD) といった手法もある。実験を通じてこれらの手法を比較する。

## どうやって有効だと検証した？

51人の被検者に、タスク下（ビデオを見る、オーディオキューを聴く、安静にする）でfMRIを時系列的に施行する。上記の信号を上記の各種手法で解析した後、SVM分類器を用いてタスクを予測し、Accuracyで評価する。結果、精度の高いものから順にL1正則化、K-SVD、各種ICA、NMFとなった。

## 技術の手法や肝は？

fMRIにおける脳機能回路の記述には、空間独立性や局在性よりも、スパース性をもたせることによってより正確に構築できる可能性を示した。しかし、これはタスクに関連する活動変化の推論に限られる点や、個体間での比較の是非わ分からないなどの制約がある。

## 議論はある？

視覚・聴覚タスクを課していない安静時に活動が更新する領域が観察され、Default Mode Networkの候補として考えられる。NMFは非負性の家庭のためにこれらを見逃してしまったため、精度が出なかったのかもしれない。

## 先行研究と比べて何がすごい？

各種手法の比較をしている点

## 次に読むべき論文は？

Predicting brain-age from multimodal imaging data captures cognitive impairment (F. Liem et al, 2016)

## Predicting brain-age from multimodal imaging data captures cognitive impairment

(2016) Franziskus Liema et al.

<https://www.biorxiv.org/content/10.1101/085506v1.full.pdf>

### どんなもの？

脳のMRI画像データから年齢を予測する。通常のMRIによる構造データ（皮質の厚さ・表面積・皮質下）と、fMRIによる機能的回路データ（SVD使用）を用意し、これらのデータが年齢予測タスクに有効かを検討する。

### どうやって有効だと検証した？

上記のデータを単体もしくは併せて使用するか、SVR単体かRandomForest (RF) とのstackingを行うかで、予測精度を絶対誤差で比較した。結果、全ての特徴量を使用しSVR:sub, RF:mainのstackingで、最も高い予測性能が得られた。

### 技術の手法や肝は？

- stacking
- SVCではC=1
- RFではout of bag estimates を決定木の深さ設定に使用した？

### 議論はある？

- 皮質については、表面積よりも厚さの方が年齢予測に寄与するようである。
- 白質の情報も取り入れることで、予測精度がさらに増すかもしれない。
- 今後、MRI画像データの標準的な処理法の開発が望まれる。

### 先行研究と比べて何がすごい？

- 複数のデータを使用したstackingモデルでは、頭部の動きによるノイズや検査機器の違いに対して堅牢とわかった。
- 予測脳年齢が実年齢よりも高かった個体を調査した結果、認知機能障害をもつ者の割合が高いことが分かった。

### 次に読むべき論文は？

Gaussian Process Uncertainty in Age Estimation as a Measure of Brain Abnormality (B. G. Becker et al. 2018)

## Gaussian Process Uncertainty in Age Estimation as a Measure of Brain Abnormality

(2018) B. G. Becker et al.

<https://arxiv.org/pdf/1804.01296.pdf>

### どんなもの？

不確実性を前提としたベイズ推定法の考え方に基づく、ガウス過程回帰を使用して健康な個体のMRI画像の形態データから、年齢予測モデルを構築した。さらにこれを用いて正常な脳の老化パターンを作成し、病的（自閉症、軽度認知機能障害、アルツハイマー型認知症）のパターンと比較した。

### どうやって有効だと検証した？

- ・ ガウス過程回帰（Gaussian Process regression）の年齢予測モデルは、MSE 3.86,  $R^2$  0.93と高い。
- ・ この年齢予測モデルが病的な脳のパターンを判別するかは、ROC曲線AUCをWilcoxon順位和検定し、帰無仮説を棄却（ $p < 6 \times 10^{-5}$ ）した。

### 技術の手法や肝は？

- ・ 不確実性が前提のモデルであり、仮説からの逸脱を確率的に評価できる
- ・ 原理的に過学習が起らず、汎化性能が高い（本論文でも、学習と検証では独立した別のデータセットを使用）

### 議論はある？

従来の予測誤差と比較し、不確実性に基づく推定の方が、疾病の有無を予測する上で優れている。理由として、脳の異常を加速老化プロセスとするのではなく、正常な脳からの逸脱としてモデル化している点が考えられる。

### 先行研究と比べて何がすごい？

- ・ GPRの不確実性を神経病理の尺度として使用することの有用性を示した点
- ・ モデルの学習には、健康な個体のデータのみがあればよい点
- ・ 高齢のアルツハイマー症例と、若年の自閉症症例を判別できていた

### 次に読むべき論文は？

Predicting brain age with deep learning from raw imaging data results in a reliable and heritable biomarker (James H Cole et al. 2016)

Predicting brain age with deep learning from raw imaging data results in a reliable and heritable biomarker

(2016) James H Cole et al.

<https://arxiv.org/ftp/arxiv/papers/1612/1612.02572.pdf>

## どんなもの？

脳MRI構造データからの年齢予測に畳み込みニューラルネットワークを使用し、ガウス過程回帰と比較した。また、一卵性・二卵性双生児のデータから、脳年齢に対する遺伝の影響をみた。さらに、異なる機器からのデータから、CNNモデルの他施設間での汎化性能をみた。

## どうやって有効だと検証した？

- CNNモデルは、予測年齢と実年齢の相関係数が  $r = 0.96$  と高い相関を示し、 $R^2 = 0.92$ ,  $MAE = 4.16$  [年]であった。
- これはガウス過程回帰 ( $r = 0.95$ ,  $R^2 = 0.89$ ,  $MAE = 4.66$  [年]) に匹敵する。
- 遺伝率は構造方程式モデリング、多施設間の汎化性能はクラス内相関係数で評価、有意だった

## 技術の手法や肝は？

- 灰白質のみではなく、白質のデータも使用
- 3D conv (3×3×3) → ReLU → 3D conv (3×3×3) → Batch Normalize → ReLU → MaxPooling (2×2×2) → Affine → output

## 議論はある？

3D CNNモデルは学習に時間がかかるが、一度学習してしまえば予測は数秒であり、加工していない生データでも予測性能が高い。この技術が運用される場面考えた際、前処理を必要としない分CNNモデルは早く予測を出す事ができ、実用性が高い。

## 先行研究と比べて何がすごい？

- 3D CNNがMRI画像からの脳年齢予測に有用であると、初めて示した点。
- 3D CNNモデルは正規化等の前処理データと同様、生データでも高い予測性能を示した点。 ( $R^2 : 0.92$  vs  $0.88$ )

## 次に読むべき論文は？

BRAIN AGE PREDICTION BASED ON RESTING-STATE FUNCTIONAL CONNECTIVITY PATTERNS USING CONVOLUTIONAL NEURAL NETWORKS (Hongming Li et al. 2018)

# BRAIN AGE PREDICTION BASED ON RESTING-STATE FUNCTIONAL CONNECTIVITY PATTERNS USING CONVOLUTIONAL NEURAL NETWORKS

(2018) Hongming Li et al.

<https://arxiv.org/ftp/arxiv/papers/1801/1801.04013.pdf>

## どんなもの？

通常のMRIの構造データではなく、安静時のfMRIから得られた機能的回路の指標値を特徴量とし、深層学習モデルを用いて年齢予測タスクを行ったもの。

## 議論はある？

CNNモデルはfMRIだけではなく多種のデータを統合するだけの柔軟性があり、特徴量の追加によって更なるパフォーマンスの向上が期待される。

## どうやって有効だと検証した？

- ・ 非負でスパース性をもつ機能的回路の指標値をラプラス近似基準を使用し、56個に絞り抽出
- ・ 上記をCNNモデル、lasso回帰モデルで学習し比較したところ、CNNモデルの方が高い性能を示した。（ $r$ : 0.614 vs 0.530, MAE 2.15 vs 2.32）

## 先行研究と比べて何がすごい？

- ・ 深層学習モデルで学習された特徴量を、主成分分析およびt分布確率的近傍法を用いて次元削減し視覚化している
- ・ 上記の分析により、年齢予測のために有用な機能回路の候補を提示している（帯状回、デフォルトモード、注意ネットワークなど）

## 技術の手法や肝は？

- ・ 3D conv → Batch Normalize → ReLU → ( MaxPooling → ResBlock ) ×3  
→ Affine 1 → ReLU → Dropout → Affine 2 → output
- ・ ResNetのスキップ構造を採用している

## 次に読むべき論文は？